

# **Introdução à teoria das probabilidades**

## **Modelos probabilísticos discretos**

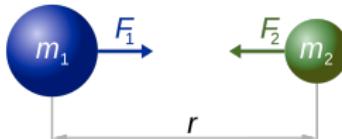
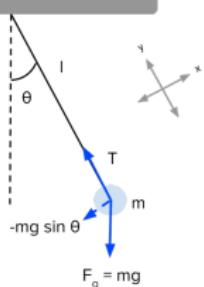
Francisco A. Rodrigues

Universidade de São Paulo

# Determinístico vs. Probabilístico

## Modelo determinístico:

- Dadas as condições iniciais, podemos prever com exatidão o resultado de um experimento.



$$F_1 = F_2 = G \frac{m_1 \times m_2}{r^2}$$

$$\nabla \cdot \mathbf{D} = \rho$$

$$\nabla \cdot \mathbf{B} = 0$$

$$\nabla \times \mathbf{E} = - \frac{\partial \mathbf{B}}{\partial t}$$

$$\nabla \times \mathbf{H} = \mathbf{J} + \frac{\partial \mathbf{D}}{\partial t}$$

# Determinístico vs. Probabilístico

## Experimento aleatório:

- ▶ Um experimento aleatório é um experimento que pode ser repetido inúmeras vezes sob as mesmas condições, sendo o seu resultado incerto.



## Determinístico vs. Probabilístico

- Quando você joga um dado, obtém uma sequência de valores.

$$X = [1, 4, 5, 6, 3, 1, 2, 3, 1, 6, 5, 3, 2, 3, 4, 3, 2, 3, 3, 4, 5, \dots]$$

- Não é possível saber qual será o próximo valor. Mas podemos determinar a probabilidade de cada resultado possível.

```
import random
moeda = ['cara', 'coroa']
for i in range(0, 10):
    # lança a moeda
    saida = random.choice(moeda)
    print(saida)
```

# Determinístico vs. Probabilístico

## Modelos probabilísticos:

- ▶ Os resultados de cada experimento parecem imprevisíveis, mas quando um grande número de experimentos é analisado, surge um padrão.
- ▶ Não podemos determinar o valor exato do resultado de um experimento, mas sim as probabilidades de cada resultado possível.
- ▶ Exemplo:

$$P(X = k) = \frac{n!}{(n - k)!k!} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n$$

# Modelos

- ▶ **Modelo determinístico:** dadas as condições iniciais de um experimento, podemos determinar o estado (por exemplo, posição, velocidade, voltagem) em qualquer instante de tempo.
- ▶ **Modelo probabilístico (estocástico):** as saídas de cada experimento parecem imprevisíveis, mas quando se analisa um grande número de experimentos, um padrão emerge. Não podemos determinar exatamente o valor da próxima saída, mas podemos calcular a probabilidade de cada resultado.

## Distribuição uniforme discreta

Se  $X$  é o valor que sai na face superior de um dado de seis faces, então a distribuição de probabilidade de  $X$  é dada por:

|            |       |       |       |       |       |       |
|------------|-------|-------|-------|-------|-------|-------|
| $X$        | 1     | 2     | 3     | 4     | 5     | 6     |
| $P(X = k)$ | $1/6$ | $1/6$ | $1/6$ | $1/6$ | $1/6$ | $1/6$ |

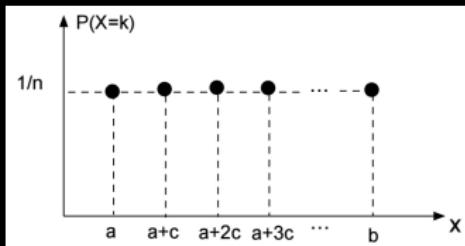
Notem que se o dado tiver mais faces, essa tabela será maior, o que pode dificultar a sua análise.

# Distribuição uniforme discreta

Seja  $X$  uma variável aleatória discreta assumindo os  $n$  valores  $\{a, a + c, a + 2c, \dots, b - c, b\}$ , ( $a, b \in \mathbb{R}$ ,  $c \in \mathbb{R}_{>0}$  e  $a < b$ ). Dizemos que  $X$  segue o modelo uniforme discreto se atribui a mesma probabilidade  $1/n$  a cada um desses valores. Isto é, sua distribuição de probabilidade é dada por

$$P(X = x) = \frac{1}{n}, \quad x = a, a + c, a + 2c, \dots, b, \quad (1)$$

onde  $n = 1 + (b - a)/c$ .



## Distribuição uniforme discreta

Seja  $X$  uma variável aleatória discreta assumindo os  $n$  valores  $\{a, a + c, a + 2c, \dots, b - c, b\}$ , ( $a, b \in \mathbb{R}$ ,  $c \in \mathbb{R}_{>0}$  e  $a < b$ ).  
Então,

$$E[X] = \frac{a + b}{2}, \quad (2)$$

$$V(X) = \frac{c^2(n^2 - 1)}{12}, \quad (3)$$

onde  $n = (b - a)/c + 1$ .





# Distribuição uniforme discreta

Para provar esse teorema, vamos definir a variável aleatória  $Y$  com  $n$  valores  $\{1, 2, \dots, n\}$  igualmente prováveis. Então, a esperança de  $Y$ :

$$\begin{aligned} E[Y] &= \sum_{k=1}^n kP(Y = k) \\ &= \frac{1}{n}(1 + 2 + \dots + n) \\ &= \frac{1}{n} \left[ \frac{n(n+1)}{2} \right] \\ &= \frac{n+1}{2}. \end{aligned}$$

Podemos escrever  $X$  em termos de  $Y$ , isto é,  $X = cY + (a - c)$ , pois  $X$  assume os  $n$  valores  $\{a, a+c, a+2c, \dots, b-c, b\}$ , ( $a, b \in \mathbb{R}$ ,  $c \in \mathbb{R}_{>0}$  e  $a < b$ ). Então:

$$\begin{aligned} E[X] &= E[cY + (a - c)] = cE[Y] + (a - c) = c \left( \frac{n+1}{2} \right) + (a - c) \\ &= \frac{c}{2} \left( \frac{b-a+c}{c} + 1 \right) + a - c = \frac{a+b}{2}. \end{aligned}$$

## Distribuição uniforme discreta

Vamos calcular a variância de  $Y$ . Para isso, o segundo momento de  $Y$  é dado por:

$$\begin{aligned} E[Y^2] &= \sum_{k=1}^n k^2 P(Y = k) \\ &= \frac{1}{n}(1^2 + 2^2 + \dots + n^2) \\ &= \frac{1}{n} \left[ \frac{n(n+1)(2n+1)}{6} \right] \\ &= \frac{(n+1)(2n+1)}{6}. \end{aligned}$$

Assim, a variância de  $Y$ :

$$\begin{aligned} V[Y] &= E[Y^2] - E[Y]^2 \\ &= \frac{(n+1)(2n+1)}{6} - \left( \frac{n+1}{2} \right)^2 \\ &= \frac{n^2 - 1}{12}. \end{aligned}$$

Calculando a variância de  $X$ :

$$V[X] = V(cY + (a - c)) = c^2 V(Y) = c^2 \left( \frac{n^2 - 1}{12} \right).$$

## Distribuição uniforme discreta

**Exemplo:** Seja  $X$  uma variável aleatória que representa a saída em um dado de 12 faces, isto é,  $X$  tem distribuição uniforme discreta em  $1, 2, \dots, 12$ , isto é,  $a = 1$ ,  $c = 1$  e  $b = 12$  na equação (1).

Assim,

$$P(X = k) = \frac{1}{12}, \quad k = 1, 2, \dots, 12.$$

Calcule o valor médio e a variância de  $X$ .



## Distribuição uniforme discreta

**Solução:** Usando o teorema anterior, para o valor esperado, temos:

$$E[X] = \frac{(1 + 12)}{2} = 6,5.$$

Como  $n = 12$ , a variância é dada por (ver equação (3)):

$$V(X) = \frac{12^2 - 1}{12} = \frac{143}{12} = 11,9.$$

# Distribuição uniforme discreta

Podemos verificar esse resultado usando o código a seguir, onde obtemos uma média igual a 6,58 e variância igual a 11,89, que são próximos dos valores teóricos.

```
import random as random
import numpy as np
# inicializa o gerador de números aleatórios
np.random.seed(10)

n = 12 # número de faces do dado
dados = np.arange(1,n+1)
print('dados:', dados)
X = [] # armazena os valores
ns = 1000 # número de simulações
for i in range(0,ns):
    # sorteia uma face do dado
    x = random.choice(dados)
    X.append(x)
print('Média = ', np.mean(X)) # calcula a média
print('Variância = ', np.var(X)) # calcula a variância
```

## Distribuição de Bernoulli

Dizemos que a variável aleatória  $X$  segue o modelo de Bernoulli se atribui 0 à ocorrência de um fracasso ou 1 à ocorrência de um sucesso, com  $p$  representando a probabilidade de sucesso,  $0 \leq p \leq 1$ , e  $1 - p$  a probabilidade do fracasso. A distribuição de probabilidade é dada por:

$$P(X = k) = p^k(1 - p)^{1-k}, \quad k = 0, 1. \quad (4)$$

| $X$        | 0       | 1   |
|------------|---------|-----|
| $P(X = k)$ | $1 - p$ | $p$ |

## Distribuição de Bernoulli

Seja  $X$  uma variável aleatória com distribuição de Bernoulli. Então:

$$E[X] = p, \quad (5)$$

$$V(X) = p(1 - p). \quad (6)$$

## Distribuição de Bernoulli

Seja  $X$  uma variável aleatória com distribuição de Bernoulli. Então:

$$E[X] = p, \quad (7)$$

$$V(X) = p(1 - p). \quad (8)$$

Prova:

$$E[X] = 0 \times (1 - p) + 1 \times p = p.$$

A variância:

$$\begin{aligned} V(X) &= E[X^2] - E[X]^2 \\ &= 0^2 \times (1 - p) + 1^2 \times p - p^2 \\ &= p - p^2 \\ &= p(1 - p). \end{aligned}$$

## Distribuição Binomial

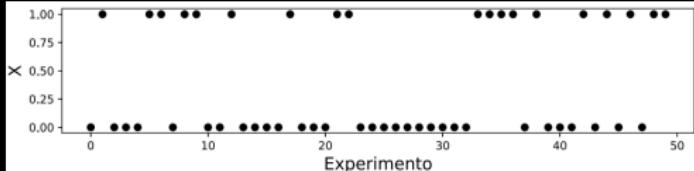
O processo estocástico de Bernoulli possui as seguintes propriedades:

- ▶ O experimento consiste de  $n$  tentativas repetidas.
- ▶ Cada tentativa gera um resultado que pode ser classificado como sucesso ou falha.
- ▶ A probabilidade de sucesso  $p$  se mantém constante de tentativa para tentativa.
- ▶ As tentativas são feitas de forma independente uma da outra.

# Distribuição Binomial

```
import numpy as np
from matplotlib import pyplot as plt
# inicializa o gerador de números aleatórios
np.random.seed(10)

n = 50 # número de experimentos
S = [] # lista que armazena as saídas
p = 0.4 # probabilidade de sucesso
for t in range(0,n):
    # gera uma saída: 0 ou 1
    if(np.random.uniform() < p):
        s = 1 # ocorre um sucesso
    else:
        s = 0 # ocorre uma falha
    S.append(s)
# mostra os resultados
plt.figure(figsize=(10,2))
plt.plot(range(0,n), S, 'ko')
plt.xlabel('Experimento', fontsize = 15)
plt.ylabel('X', fontsize = 15)
plt.show(True)
print(S)
```



## Distribuição Binomial

Seja  $X$  uma variável aleatória baseada em  $n$  repetições de um processo de Bernoulli. Então a probabilidade de obtermos  $k$  sucessos em  $n$  repetições é dada por:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n, \quad (9)$$

onde

$$C_n^k = \binom{n}{k} = \frac{n!}{(n - k)!k!},$$

é uma combinação de  $n$  elementos tomados de  $k$  em  $k$ .

## Distribuição Binomial

**Exemplo:** A probabilidade de que uma peça será aceita em uma linha de produção é igual a  $\frac{3}{4}$ . Determine a probabilidade de que exatamente duas dentre quatro peças serão aceitas.

## Distribuição Binomial

**Solução:** Nesse caso, temos  $n = 4$ ,  $k = 2$  e  $p = \frac{3}{4}$ . Assim,

$$P(X = 2) = \binom{4}{2} p^2 (1-p)^{4-2} = \frac{4!}{2!2!} \left(\frac{3}{4}\right)^2 \left(1 - \frac{3}{4}\right)^2 = \frac{27}{128} = 0,21.$$

Logo, a probabilidade de que duas, dentre quatro peças, sejam aceitas é igual a 0,21.

## Distribuição Binomial

**Exemplo:** A probabilidade de que um estudante seja aprovado em um processo seletivo é igual 0,4. Se 15 estudantes estão realizando a prova, qual a probabilidade de que:

- a) Exatamente 5 sejam aprovados?
- b) Pelo menos 10 sejam aprovados?
- c) De 3 a 8 pessoas sejam aprovados?

## Distribuição Binomial

Seja  $X$  é uma variável aleatória com distribuição binomial e parâmetros  $n$  e  $p$ , então

$$E[X] = np, \quad (10)$$

$$V[X] = np(1 - p) \quad (11)$$

# Distribuição Binomial

Para demonstrar esse teorema, vamos definir a variável aleatória que indica a ocorrência de um sucesso, que ocorre com probabilidade  $p$ , também chamada de função indicadora. Assim,

$$Y_i = \begin{cases} 1 & \text{se um sucesso ocorre na } i\text{-ésima repetição,} \\ 0 & \text{se não ocorre.} \end{cases}$$

Logo,  $Y_i$  segue o modelo de Bernoulli.

$$P(Y_i = k) = p^k(1 - p)^{1-k}, \quad k = 0, 1.$$

De acordo com as equações (7) e (8), temos:

$$E[Y_i] = p, \quad V[Y_i] = p(1 - p).$$

Podemos escrever o número de sucessos  $X$  em termos de  $Y_i$ :

$$X = Y_1 + Y_2 + \dots + Y_n, \tag{12}$$

pois  $Y_i$  indica uma ocorrência do sucesso na tentativa  $i$ ,  $i = 1, 2, \dots, n$ .

Calculando a esperança em ambos os lados da equação (12), temos:

$$\begin{aligned} E[X] &= E[Y_1 + Y_2 + \dots + Y_n] \\ &= E[Y_1] + E[Y_2] + \dots + E[Y_n] \\ &= p + p + \dots + p = np. \end{aligned}$$

# Distribuição Binomial

De maneira similar, calculando a variância de  $X$ :

$$\begin{aligned}V(X) &= V(Y_1 + Y_2 + \dots + Y_n) \\&= V(Y_1) + V(Y_2) + \dots + V(Y_n) \\&= np(1 - p).\end{aligned}$$

No caso da variância, usamos o fato de que se  $X$  e  $Y$  são duas variáveis aleatórias independentes, então  $V(X + Y) = V(X) + V(Y)$ . Isto é,

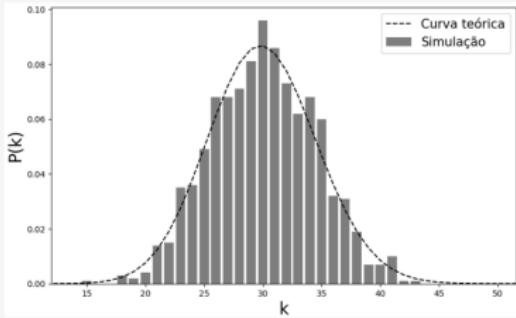
$$\begin{aligned}V(X + Y) &= E[(X + Y)^2] - (E[(X + Y)])^2 \\&= E[X^2 + 2XY + Y^2] - E[X]^2 - 2E[X]E[Y] - E[Y]^2 \\&= E[X^2] - E[X]^2 + E[Y^2] - E[Y]^2 + 2E[XY] - 2E[X]E[Y] \\&= V(X) + V(Y) + 2E[XY] - 2E[X]E[Y].\end{aligned}$$

Assim,  $V(X + Y) = V(X) + V(Y)$  se, e somente se,  $E[XY] = E[X]E[Y]$ . Com isso, provamos o teorema anterior.

# Distribuição Binomial

```
from matplotlib import pyplot as plt
import numpy as np
from scipy.stats import binom
import math
np.random.seed(42)

n = 100 # número de lançamentos
p = 0.3 # probabilidade de sair cara
Pk = np.zeros(n)
vk = np.arange(0,n)
ns = 1000 # número de simulações
# simula a distribuição binomial
for j in range(0,ns): # realiza ns simulações
    S = 0 # número de sucessos
    for i in range(0,n): # para n lançamentos
        if(np.random.uniform() <= p): # se sair um sucesso
            S = S + 1
    Pk[S] = Pk[S] + 1
Pk=Pk/sum(Pk) # normaliza a distribuição de probabilidade
# mostra os resultados da simulações
plt.figure(figsize=(10,6))
plt.xlim(0.8*np.min(vk[Pk>0]),1.2*np.max(vk[Pk>0]))
plt.bar(vk, Pk, color ='gray', label='Simulação')
# mostra a curva teorica
Pkt = np.zeros(n+1) # valores teóricos da probabilidade
vkt = np.arange(0,n+1) # variação em k
for k in range(0,n+1): # varia de 0 ate n
    C = (math.factorial(n)/(math.factorial(n-k)*math.factorial(k)))
    Pkt[k] = C*(p**k)*(1-p)**(n-k)
plt.plot(vkt, Pkt, color ='black', linestyle = 'dashed', label='Curva teórica')
plt.xlabel('k', fontsize = 20)
plt.ylabel('P(k)', fontsize = 20)
plt.legend(fontsize = 15)
plt.savefig('binomial.svg')
plt.show(True)
```



## Distribuição Multinomial

Seja  $X_i$  a variável aleatória que representa o número de saídas do evento  $i$  em  $n$  experimentos. Cada saída  $X_i$  ocorre com probabilidade  $p_i$ ,  $i = 1, 2, \dots, k$ . Então, a probabilidade de observar o vetor aleatório  $(X_1 = x_1, X_2 = x_2, \dots, X_k = x_k)$  é dada por:

$$P(X_1 = x_1, X_2 = x_2, \dots, X_k = x_k) = \frac{n!}{x_1! x_2! \dots x_k!} p_1^{x_1} p_2^{x_2} \dots p_k^{x_k}, \quad (13)$$

onde

$$\sum_{i=1}^k p_i = 1.$$

O termo

$$\frac{n!}{x_1! x_2! \dots x_k!}$$

é a permutação de  $n$  elementos com repetição.

## Distribuição Multinomial

**Exemplo:** Três jogadores de cartas iniciam uma série de jogos. A probabilidade do jogador  $A$  ganhar um jogo é igual 20%, enquanto que a probabilidade de que  $B$  vença é igual a 30% e para o jogador  $C$ , 50%. Se eles jogarem seis jogos, qual é a probabilidade de que  $A$  vença um jogo,  $B$  vença dois jogos e  $C$  vença três jogos?

## Distribuição Multinomial

**Solução:** Como temos três saídas possíveis e os jogos são independentes, temos um exemplo de aplicação da distribuição multinomial. Seja  $X_A$ ,  $X_B$  e  $X_C$  as variáveis aleatórias que representam o número de vitórias de  $A$ ,  $B$  e  $C$ , respectivamente. Assim, usando a equação (13):

$$P(X_A = 1, X_B = 2, X_C = 3) = \frac{6!}{1!2!3!}(0,2)^1(0,3)^2(0,5)^3 = 0,135.$$

# Distribuição Multinomial

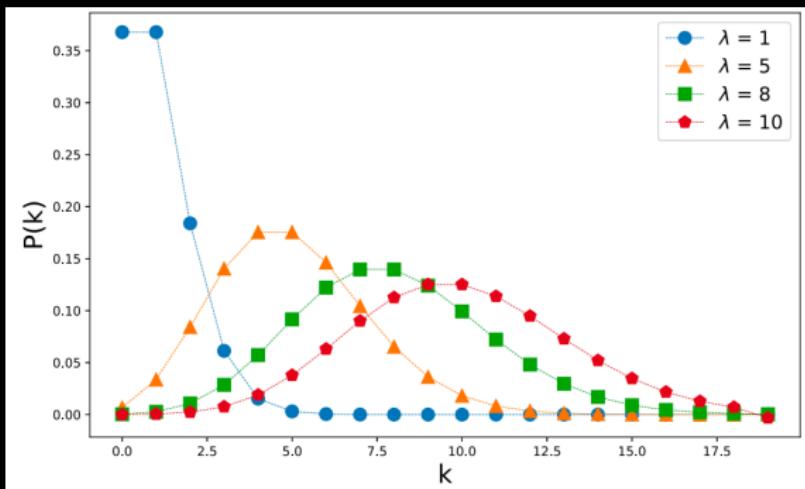
Podemos simular esse problema considerando o código a seguir.  
Para uma execução, obtemos o valor 0,136, que é próximo da probabilidade teórica.

```
import numpy as np
# inicializa o gerador de números aleatórios
np.random.seed(101)
#probabilidades
pA = 0.2 # prob. do evento A
pB = 0.3 # prob. do evento B
pC = 0.5 # prob. do evento C
nsim = 1000 # número de simulações
ns = 0 # número de sucessos
for s in range(0,nsim):
    # número de vitórias de cada jogador
    nA = 0; nB = 0; nC = 0;
    # para os 6 jogos
    for n in range(0,6):
        num = np.random.uniform()
        if(num <= pA):
            nA = nA + 1
        else:
            if(num < pA + pB):
                nB = nB + 1
            else:
                nC = nC + 1
    # se A vence uma partida, B duas e C três
    if(nA == 1 and nB == 2 and nC == 3):
        ns = ns + 1
print('P(XA=1,XB=2,XC=3)=' ,ns/nsim)
```

# Distribuição de Poisson

Uma variável aleatória discreta  $X$  segue o modelo de Poisson com taxa  $\lambda > 0$  se

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots \quad (14)$$



## Distribuição de Poisson

**Exemplo:** Em uma central de atendimento ao cliente chegam, em média, 120 mensagens por hora. Qual a probabilidade de que:

- a) em um minuto não chegue nenhuma mensagem?
- b) em 2 minutos chegam 2 mensagens?
- c) em  $t$  minutos não chegue nenhuma mensagem?

# Distribuição de Poisson

**Solução:** a) em um minuto não chegue nenhuma mensagem?

Como a taxa  $\lambda$  está em horas, precisamos convertê-la para minutos, pois queremos calcular a probabilidade de que em um minuto não chegue nenhuma mensagem. Usando regra de três:

$$120 \text{ emails} \rightarrow 60 \text{ minutos}$$

$$\lambda \text{ emails} \rightarrow 1 \text{ minuto}$$

Ou seja,

$$1 \times 120 = \lambda \times 60$$

$$\lambda = \frac{120}{60}$$

$$\lambda = 2 \text{ emails por minuto.}$$

Portanto,

$$P(X = 0) = \frac{e^{-2} 2^0}{0!} = 0,135.$$

Portanto, a probabilidade de que em um minuto não chegue nenhuma mensagem é próxima de 13%.

# Distribuição de Poisson

b) em 2 minutos chegam 2 mensagens?

120 emails → 60 minutos

$\lambda$  emails → 2 minutos

$$\lambda = \frac{2 \times 120}{60} = 4 \text{ mensagens a cada 2 minutos.}$$

$$P(X = 2) = \frac{e^{-4} 4^2}{2!} = 0,14.$$

c) em  $t$  minutos não chegue nenhuma mensagem?

Usando regra de três, temos:

120 emails → 60 minutos

$\lambda$  emails →  $t$  minutos

Resolvendo:

$$\lambda = \frac{120 \times t}{60} = 2t.$$

$$P(X = 0) = \frac{e^{-2t} (2t)^0}{0!} = e^{-2t}.$$

Logo, a probabilidade de não chegar nenhuma mensagem em  $t$  minutos decresce exponencialmente com o tempo, medido em minutos.

## Distribuição de Poisson

Seja  $X$  uma variável aleatória com distribuição de Poisson. Então,

$$E[X] = \lambda, \quad (15)$$

$$V(X) = \lambda. \quad (16)$$

Prova:

$$\begin{aligned} E[X] &= \sum_{k=0}^{\infty} k P(X = k) = \sum_{k=0}^{\infty} k \frac{e^{-\lambda} \lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} \\ &= e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{(k-1)!} = e^{-\lambda} \lambda \sum_{k=0}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \\ &= e^{-\lambda} \lambda e^{\lambda} = \lambda \end{aligned}$$

Logo,

$$E[X] = \lambda.$$

# Distribuição de Poisson

No caso da variância, vimos que  $V[X] = E[X^2] - E[X]^2$ . Assim:

$$E[X^2] = \sum_{k=0}^{\infty} k^2 \frac{e^{-\lambda} \lambda^k}{k!} = \sum_{k=0}^{\infty} e^{-\lambda} \frac{k^2 \lambda^k}{k(k-1)!} = \sum_{k=0}^{\infty} e^{-\lambda} \frac{k \lambda^k}{(k-1)!}.$$

Fazendo  $u = k - 1$ , temos:

$$\begin{aligned} E[X^2] &= \sum_{u=0}^{\infty} e^{-\lambda} \frac{(u+1)\lambda^{u+1}}{u!} \\ &= \sum_{u=0}^{\infty} e^{-\lambda} \left( \frac{u\lambda^{u+1} + \lambda^{u+1}}{u!} \right) \\ &= \lambda \sum_{u=0}^{\infty} e^{-\lambda} \left( \frac{u\lambda^u + \lambda^u}{u!} \right) \\ &= \lambda \sum_{u=0}^{\infty} u \frac{e^{-\lambda} \lambda^u}{u!} + \lambda \sum_{u=0}^{\infty} \frac{e^{-\lambda} \lambda^u}{u!} \\ &= \lambda(\lambda) + \lambda(1) \\ &= \lambda^2 + \lambda. \end{aligned}$$

Assim,

$$V[X] = E[X^2] - E[X]^2 = \lambda^2 + \lambda - \lambda^2 = \lambda.$$

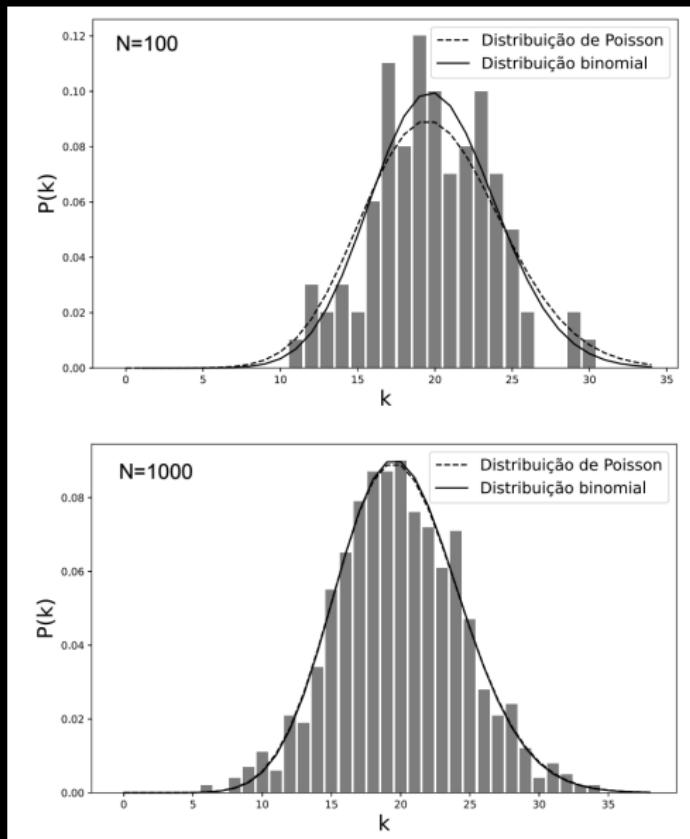
## Distribuição de Poisson

Seja  $X$  uma variável aleatória com distribuição binomial e  $p$  a probabilidade de sucesso. Então,

$$\lim_{n \rightarrow \infty} \binom{n}{k} p^k (1-p)^{n-k} = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots, \quad (17)$$

onde  $\lambda = np$  é constante.

# Distribuição de Poisson



## Distribuição de Poisson

**Exemplo:** Suponha que em um hospital, o número médio de pacientes que chega à emergência é de 120 por dia. Queremos calcular a probabilidade de que cheguem exatamente 10 pacientes em uma hora.

## Distribuição de Poisson

**Solução:** Primeiro, precisamos converter a taxa média de chegadas de pacientes para uma base horária. Sabemos que há 24 horas em um dia, então a taxa de chegadas por hora  $\lambda_{\text{hora}}$  é:

$$\lambda_{\text{hora}} = \frac{120 \text{ pacientes/dia}}{24 \text{ horas/dia}} = 5 \text{ pacientes/hora}$$

Agora que temos a taxa correta, podemos aplicar a fórmula da distribuição de Poisson para calcular a probabilidade de que exatamente 10 pacientes cheguem em uma hora:

$$P(X = 10) = \frac{\lambda_{\text{hora}}^{10} e^{-\lambda_{\text{hora}}}}{10!} = \frac{5^{10} e^{-5}}{10!} \approx 0,0018$$

A probabilidade de que exatamente 10 pacientes cheguem à emergência em uma hora é aproximadamente 1,8%.

## Distribuição geométrica

Dizemos que a variável aleatória discreta  $X$  segue uma distribuição geométrica se:

$$P(X = k) = p(1 - p)^{k-1}, \quad k = 1, 2, \dots \quad (18)$$

# Distribuição geométrica

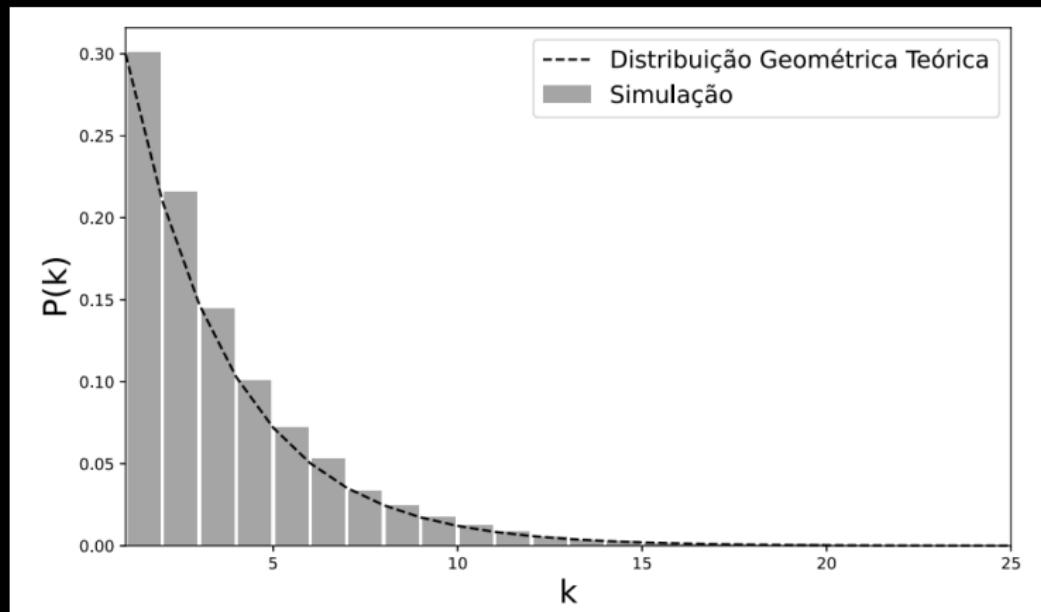
```
from matplotlib import pyplot as plt
import numpy as np
from scipy.stats import geom
np.random.seed(10)

p = 0.3 # probabilidade de um sucesso
X = [] # Armazena o número de experimentos
ns = 10000 # número de simulações
for i in range(0,ns):# para ns simulações
    k = 0 # número de experimentos
    s = False # variável que indica uma falha
    while s == False: # enquanto não sair um sucesso
        r = np.random.uniform() # sorteia um numero entre 0 e 1
        if(r <= p): # se for um sucesso
            s = True # indica um sucesso
        k = k + 1 # incrementa o número de experimentos
    X.append(k) # guarda o número de experimentos

k = np.arange(0, np.max(X))
# mostra os resultados da simulação
plt.figure(figsize=(10,6))
count, bins, ignored = plt.hist(X, bins=k, density=True,
                                color='gray', alpha=0.7,
                                rwidth=0.9, label='Simulação')
plt.xlabel('k', fontsize = 20)
plt.ylabel('P(k)', fontsize = 20)

# mostra a distribuição teórica
x = np.arange(1,np.max(k)+5)
px = geom(p)
plt.plot(x,px.pmf(x), '--', color ='black',
          label='Distribuição Geométrica Teórica')
plt.xlim(1,max(x))
plt.legend(fontsize =15)
plt.savefig('geometric.svg')
plt.show(True)
```

# Distribuição geométrica



## Distribuição geométrica

**Exemplo:** A probabilidade de sair cara em um lançamento é igual a  $p = 0,3$ . Qual é a probabilidade de que saia a primeira cara no quinto lançamento?

## Distribuição geométrica

**Solução:** Nesse caso, temos quatro lançamentos como coroa e o último como cara. Seja  $X$  o número de lançamentos necessários. Então

$$P(X = 5) = p(1 - p)^{5-1} = 0,3(1 - 0,3)^4 = 0,072.$$

Podemos interpretar essa probabilidade como sendo a fração de vezes em que lançamos uma moeda e a primeira cara sai no quinto lançamento.

## Distribuição geométrica

**Exemplo:** Suponha que temos uma urna com 36 bolas, sendo 27 bolas brancas e 9 pretas. Bolas são retiradas até que uma bola preta apareça. Qual é a probabilidade de que precisaremos de mais de seis retiradas para sortear a primeira bola preta?

## Distribuição geométrica

**Solução:** Seja  $X$  o número de retiradas necessárias. Então, vamos calcular:

$$P(X > 6) = 1 - P(X \leq 6) = 1 - \sum_{k=1}^6 \left(\frac{9}{36}\right) \left(1 - \frac{9}{36}\right)^{k-1} = 0,178.$$

Assim, a probabilidade de que precisaremos de mais de seis lançamentos é aproximadamente igual a 18%.

## Distribuição geométrica

Seja  $X$  uma variável aleatória com distribuição geométrica. Então,

$$E[X] = \frac{1}{p}, \quad (19)$$

$$V(X) = \frac{1-p}{p^2}. \quad (20)$$

# Distribuição geométrica

Para verificar esse teorema, usamos a definição do valor esperado de uma variável aleatória:

$$E[X] = \sum_{k=0}^{\infty} kP(X = k) = \sum_{k=0}^{\infty} kp(1 - p)^{k-1}.$$

Fazendo  $x = 1 - p$ ,

$$\begin{aligned} E[X] &= (1 - x) \sum_{k=0}^{\infty} kx^{k-1} = (1 - x) \sum_{k=0}^{\infty} \frac{d}{dx} x^k \\ &= (1 - x) \frac{d}{dx} \sum_{k=0}^{\infty} x^k = (1 - x) \frac{d}{dx} \left( \frac{1}{1 - x} \right) \\ &= (1 - x) \frac{1}{(1 - x)^2} = \frac{1}{1 - x} = \frac{1}{p}. \end{aligned}$$

Notem que usamos a série geométrica  $\sum_{n=0}^{\infty} x^n = 1/(1 - x)$ . Usando o mesmo raciocínio para a variância, vamos obter:

$$V(X) = E[X^2] - E[X]^2 = \sum_{k=0}^{\infty} k^2 p(1 - p)^{k-1} - \left( \frac{1}{p} \right)^2 = \frac{1 - p}{p^2}.$$

## Distribuição binomial negativa

Seja  $X$  o número de repetições necessárias a fim de que ocorram exatamente  $r$  sucessos de modo que o  $r$ -ésimo sucesso ocorra na  $k$ -ésima tentativa. Então,

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots \quad (21)$$

## Distribuição binomial negativa

**Exemplo:** Uma série da liga de futebol amador de uma cidade, o time que ganhar quatro jogos em sete será o vencedor. Suponha que o time A tenha probabilidade  $p = 0,6$  de ganhar do time B.

- a) Qual é a probabilidade de que A vença a série em seis jogos?
- b) Qual é a probabilidade de que A perca a série em cinco jogos?
- c) Qual é a probabilidade de que A vença a série?



# Distribuição binomial negativa

**Solução:** a) Qual é a probabilidade de que A vença a série em seis jogos?

Para que A vença em seis jogos, esse time deve vencer  $r = 4$  partidas e perder duas, sendo que a última partida necessariamente deve ser uma vitória do time A. Assim,

$$P(X = 6) = \left( \binom{6-1}{4-1} (0,6)^{4-1} (1-0,6)^{(6-1)-(4-1)} \right) \times 0,6 = 0,207.$$

Logo, a probabilidade é próxima de 21%.

b) Qual é a probabilidade de que A perca a série em cinco jogos?

A probabilidade de que o time A perca um jogo é igual a  $1 - 0,6 = 0,4$ . Seja  $X$  o número de jogos necessários para o time  $B$  vencer a série em cinco jogos. Assim, dentre 4 jogos iniciais,  $B$  vence 3 e perde 1. No último jogo, B consegue mais uma vitória e finaliza a série. Assim, a probabilidade de B vencer a série em cinco jogos é dada por:

$$P(X = 5) = \left[ \binom{4}{3} (0,4)^3 (1-0,4)^{4-3} \right] \times 0,4 = 0,061.$$

Logo, a probabilidade de A perder a série em 5 jogos é próxima de 6%.

## Distribuição binomial negativa

c) Qual é a probabilidade de que A vença a série?

Para que A vença a série, A deve (i) vencer quatro jogos em sequência, ou (ii) vencer quatro jogos e perder um jogo, ou (iii) vencer quatro jogos e perder dois jogos, ou (iv) vencer quatro jogos e perder três jogos.

$$P(\text{"A vencer a série"}) = P(X \geq 4)$$

$$\begin{aligned} &= \sum_{k=4}^7 \binom{k-1}{4-1} (0,6)^{3-1} (1-0,6)^{(k-1)-(4-1)} \times 0,6 \\ &= 0,71. \end{aligned}$$

Notem que a probabilidade de A vencer a série é maior do que a de A vencer apenas um dos jogos.

## Distribuição hipergeométrica

Considere um conjunto de  $N$  objetos, dos quais  $N_1$  são do tipo 1 e  $N_2 = N - N_1$  são do tipo 2. Para um sorteio de  $n$  objetos ( $n < N$ ) sem reposição, seja  $X$  a variável aleatória que define o número de objetos do tipo 1 sorteados. Então, a probabilidade de sortearmos  $k$  objetos do tipo 1:

$$P(X = k) = \frac{\binom{N_1}{k} \binom{N-N_1}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, \dots, n. \quad (22)$$

## Distribuição hipergeométrica

**Exemplo:** Em uma fábrica de sucos, garrafas de um litro são embaladas em caixas de 25 unidades. Para aceitar esse lote, o funcionário de uma loja sorteia cinco garrafas e mede a quantidade de líquido que cada garrafa contém. Se dentre as cinco garrafas sorteadas, no máximo duas apresentarem menos de um litro de suco, o lote é aceito. Sabendo-se que um lote tem quatro garrafas com menos de um litro de suco, qual é a probabilidade desse lote ser aceito?

## Distribuição hipergeométrica

**Solução:** Seja  $X$  a variável aleatória que representa o número de garrafas com menos de um litro sorteadas. Assim, temos:

$$\begin{aligned}P(X \leq 2) &= 1 - P(X < 2) \\&= 1 - P(X = 0) - P(X = 1) \\&= 1 - \frac{\binom{4}{0} \binom{21}{5}}{\binom{25}{5}} - \frac{\binom{4}{1} \binom{21}{4}}{\binom{25}{5}} \\&= 0,98.\end{aligned}$$

Logo, temos 98% de probabilidade de aceitar o lote.

# Sumário

- ▶ Modelo Uniforme.
- ▶ Modelo de Bernoulli.
- ▶ Distribuição Binomial.
- ▶ Distribuição Geométrica.
- ▶ Distribuição Poisson.
- ▶ Distribuição Binomial Negativa.
- ▶ Distribuição Hipergeométrica.